

HDB 转售价格分析系统 — 代码文件说明

项目概述

基于 Streamlit 的新加坡 HDB 组屋转售价格分析与预测系统，覆盖 Punggol、Sengkang、Hougang 三个镇区。共 6 个功能页面，采用 pydeck 地图可视化、Plotly 交互式图表、Scikit-learn 机器学习模型。

文件结构

```
hdb-resale-analysis/
├── app.py                # 主入口文件：Streamlit 页面路由
├── requirements.txt       # Python 依赖包列表
├── .gitignore            # Git 忽略规则
├── README.md             # 项目说明
├── data/
│   ├── __init__.py       # 包初始化
│   ├── data_loader.py    # 数据获取、清洗、缓存管线
│   └── hdb_cache.parquet  # HDB 转售数据缓存（清洗后 34,914 条）
├── pages/
│   ├── __init__.py       # 包初始化
│   ├── 01_overview.py    # 第 1 页：数据概览（多维筛选 + 统计看板 + 趋势图 + 数据表）
│   ├── 02_map.py         # 第 2 页：地图可视化（pydeck 均价/热力/时空 + MRT/学校叠加）
│   ├── 03_factors.py     # 第 3 页：影响因素分析（6 因素 7 Tab + 统计检验 + Town vs Price）
│   ├── 04_prediction.py  # 第 4 页：价格预测（Ridge + RF 双模型 + CV + 交互式预测 + 相似成交）
│   ├── 05_questions.py   # 第 5 页：分析思考题（3 题 × 数据分析 + 200+ 字论述）
│   └── 06_strategy.py    # 第 6 页：策略验证（4 策略 + 硬时间切分 + 7 项指标回溯）
├── utils/
│   ├── __init__.py       # 包初始化
│   └── helpers.py        # 工具函数（价格格式化、颜色映射、镇区坐标、模型指标计算）
└── docs/
    ├── 项目报告.md       # 项目报告文档
    ├── 答辩PPT.md        # 答辩 PPT 内容大纲
    └── 代码文件说明.md   # 本文件
```

运行方式

```
# 1. 安装依赖
pip install -r requirements.txt

# 2. 启动应用
streamlit run app.py
```

```
# 3. 浏览器访问
# http://localhost:8501
```

文件功能详解

app.py — 主入口

- 设置 Streamlit 页面配置 (标题、图标、宽屏布局)
- 通过 `importlib` 动态加载 6 个功能页面模块
- 侧边栏导航 (radio 选择器)
- 调用 `load_data()` 加载数据 → 传递给当前页面的 `run(df)` 函数

data/data_loader.py — 数据管线

- `fetch_hdb_data(force_refresh)` : 从 data.gov.sg API 分页获取数据, 本地 Parquet 缓存, API 失败时降级使用缓存
- `clean_hdb_data(df)` : 12 步数据清洗流程 (镇区筛选、日期解析、数值转换、剩余年限计算、房型标准化、楼层解析、单价计算、异常值剔除等)
- `load_data(force_refresh)` : 完整管线 `fetch` → `clean`

data/hdb_cache.parquet — 数据缓存

- 内置 HDB 转售数据缓存, 清洗后目标镇区 34,914 条
- 确保 Streamlit Cloud 部署时无需网络也可运行

pages/01_overview.py — 数据概览

- `_build_sidebar_filters()` : 9 项筛选控件 (全选/清除快捷按钮)
- `_apply_filters()` : 多条件组合筛选
- `_render_stats_dashboard()` : 8 指标卡片 + 镇区分组统计表
- `_render_trend_chart()` : 月度均价走势 (Plotly 折线图)
- `_render_volume_chart()` : 季度交易量 (Plotly 柱状图)
- `_render_price_distribution()` : 价格分布直方图
- `_render_town_type_matrix()` : 镇区×房型 均价热力图
- `_render_data_table()` : 可配置列的交互式数据表 + CSV 导出

pages/02_map.py — 地图可视化 (pydeck)

- `_build_town_avg_map()` : 镇区均价 ScatterplotLayer 地图 (圆圈大小=交易量, 颜色=均价)
- `_build_heatmap()` : 房价热力图 HeatmapLayer (含坐标抖动仿真 + 可调半径/强度)
- `_build_temporal_map()` : 年份滑块地图 (统一色阶跨年对比)

- `_add_overlay_layers()` : MRT 站点 + 学校 ScatterplotLayer 叠加 (侧边栏多选控制)
- `_render_temporal_chart()` : 年度价格趋势线图 + 涨跌幅热力图
- `_render_town_stats_table()` : 镇区分组统计表
- 内置 MRT_STATIONS (9 个站点: NE13-NE17 + LRT 线路) 和 SCHOOLS (5 小学 + 5 中学) 坐标数据

pages/03_factors.py — 影响因素分析

- **7 个分析 Tab**: ① 面积 / ② 房型 / ③ 楼层 / ④ 剩余租约 / ⑤ 房龄 / ⑥ 镇区对比 / 💡 策略验证
- `_analyze_area()` : 单价 vs 面积散点图 + OLS 趋势线 + Pearson 相关系数
- `_analyze_flat_type()` : 总价箱线图 + ANOVA 检验 + 逐级溢价分析
- `_analyze_storey()` : 楼层箱线图 + 趋势分析
- `_analyze_lease()` : 分箱箱线图 + 散点图 + 折旧斜率
- `_analyze_age()` : 房龄 vs 价格 LOWESS 趋势
- `_analyze_town_comparison()` : Town vs Price 偏离度分析 + CAGR (替代旧版成熟/非成熟对比框架)
- `_analyze_strategy()` : 4 策略回测 + 季度趋势 + 雷达图 + 策略说明
- 仅使用三镇区数据 (TARGET_TOWNS = ["PUNGGOL", "SENGKANG", "HOUGANG"])

pages/04_prediction.py — 价格预测

- **特征工程 (8 特征)** : 房龄、房型序数编码 (2-Room=1 → Executive=5)、MRT 距离 (Haversine 公式)、学校数量、剩余租约、面积、楼层中位、年份 + town (OneHot 编码)
- 预测目标: **单价 price_per_sqm (新元/sqm)**
- **硬时间切分**: 2020–2023 训练集 / 2024+ 测试集 (禁止随机划分)
- 模型选择: Ridge / RandomForest (侧边栏勾选)
- **超参调整**: st.slider 交互调节 (alpha、n_estimators、max_depth)
- **分房型评估 (核心)** : 6 类别分别计算 MAE/MAPE/R²
 - 小户型 (2-Room, 3-Room)
 - 中户型 (4-Room)
 - 大户型 (5-Room, Executive)
 - 老旧组屋 (房龄 ≥ 35 年)
 - 新近组屋 (房龄 < 15 年)
 - MRT 沿线 (MRT 距离 < 500m)
- 模型评估: MAE / RMSE / R² / MAPE 指标卡片
- 交叉验证: 5-fold CV, 报告 MAE 均值±标准差、R² 均值±标准差
- 预测 vs 实际散点图 (按房型着色) + y=x 参考线
- 残差诊断: 残差分布直方图 + 残差 vs 预测值散点图
- 特征重要性: RF 基尼重要性 (聚合) + Ridge 标准化系数对比

- 交互式预测表单：用户输入 → 多模型预测 → 90% 预测区间 (RF 个体树分位数)
- **四级渐进式相似成交匹配：**
 - `_find_similar()` 函数：面积 $\pm 10 \rightarrow \pm 15 \rightarrow \pm 20 \rightarrow \pm 30$ sqm + 租约放宽 + 兜底同镇区+同房型
 - 返回使用何种筛选范围和 Top 10 最近似交易

pages/05_questions.py — 分析思考题

- **3 个 Tab**，每题含图表 + 数据分析 + `st.write` ≥ 200 字论述
- **Q1 — 保值性分析：**
 - 面积—价格基本盘 / 剩余租约—时间折扣 / 镇区—地段溢价三层框架
 - CAGR 年化复合增长率计算 (分面积/房龄/镇区维度)
 - Haversine 公式计算 MRT 距离
- **Q2 — 策略方向论证：**
 - 4 策略逻辑推演：镇区偏离回归 / MRT 便利 / 长剩余租约 / 低总价入门
 - Train/Test 数据支撑分析
 - 策略选择理由论述
- **Q3 — 模型可靠性分析：**
 - Ridge vs RF 时间切分对比
 - 5-fold CV 验证
 - 残差诊断 + 适用场景 + 模型局限性
- 仅使用 3 镇区数据，不引入外部数据源
- 技术栈：RandomForestRegressor / Ridge / StandardScaler / OneHotEncoder / ColumnTransformer

pages/06_strategy.py — 策略验证

- **4 种策略类型：**
 - 镇区偏离回归策略：买低于镇区均价 → 等待价格回归
 - MRT 便利策略：买靠近 MRT → 享受交通溢价
 - 长剩余租约策略：买租约最长 → 减少折旧损失
 - 低总价入门策略：买低总价小户型 → 降低入场门槛
- **硬 2023/2024 时间切分** (防作弊)：2020–2023 策略形成期，2024+ 验证期
- 策略设定：策略类型选择 + 预算上限 + 户型范围 + 候选镇区
- 选择规则随策略类型而变：价格偏离度最小/MRT 距离最近/剩余租约最长/总价最低
- **7 项验证指标：**总涨幅 / CAGR / 价格波动 CV / 年度涨幅标准差 / 最大回撤 / 成交量 CV / 预算适配性(%)
- 策略组 vs 基准组：对比表格 + 季度均价走势折线图 + 关键指标差异柱状图
- **策略反思：**`st.write` 200+ 字 (策略选择理由 / 优劣势 / 市场变化影响 / 改进方向)

utils/helpers.py — 工具函数

- `TOWN_COLORS` : 三镇区配色映射 (Plotly 图表用)
- `TOWN_COORDS` : 三镇区经纬度坐标 (地图用)
- `fmt_price()` : 新元金额格式化 (K/M 单位)
- `fmt_pct()` : 百分比格式化
- `get_model_metrics()` : 计算 MAE / RMSE / R²

架构说明

页面导航机制

`app.py` 使用 `importlib.import_module()` 动态加载 `pages/` 目录下的页面模块, 每个页面暴露一个 `run(df)` 函数。侧边栏 radio 选择器切换页面时, 仅调用对应模块的 `run()` 函数。这种设计:

- 避免一次导入所有页面 (减少启动时间)
- 页面间完全解耦 (各自独立维护)
- 通过 `df` 参数传递共享数据 (数据只加载一次)

数据流

```
data.gov.sg API
  ↓
data_loader.fetch_hdb_data() ↔ hdb_cache.parquet
  ↓
data_loader.clean_hdb_data()
  ↓
load_data() @st.cache_data
  ↓
app.py → page.run(df)
```

防止数据泄露 (策略验证)

策略验证页面采用硬时间切分:

- `train_df = df[df["year"] <= 2023]` — 策略形成期
- `test_df = df[df["year"] >= 2024]` — 策略验证期
- 策略定义仅使用训练期数据, 验证仅使用测试期数据

Town vs Price 偏离度框架

替代传统的成熟/非成熟二分法, 采用:

- $\text{偏离度} = (\text{镇区均价} - \text{三镇区基线均价}) / \text{基线均价} \times 100\%$

- 三镇区基线均价 = Punggol / Sengkang / Hougang 的等权均值
- CAGR（年化复合增长率）作为保值潜力代理指标

依赖说明

依赖	版本要求	用途
streamlit	≥1.28.0	Web 应用框架
pandas	≥2.0.0	数据处理
numpy	≥1.24.0	数值计算
scikit-learn	≥1.3.0	机器学习模型
plotly	≥5.15.0	交互式图表
pydeck	≥0.8.0	交互式地图
requests	≥2.31.0	HTTP API 请求
scipy	≥1.10.0	统计检验
statsmodels	≥0.14.0	统计分析